

Penerapan Data Mining dengan Metode Regresi Linear untuk Memprediksi Data Nilai Hasil Ujian Menggunakan RapidMiner

JISKA (Jurnal Informatika Sunan Kalijaga)

Dosen Pengampu :

Dr. Ali Khumaidi, S.Kom, M.Kom



Dibuat Oleh :

1. 2270231030 – Tegar Witjaksono
2. 2270231013 – Reksa Dwi Febrian
3. 2270231039 – Risma Damayanti
4. 2270231019 – Rais Rasyad Shidiq

TEKNIK INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS KRISNADWIPAYANA

PENDAHULUAN

Perkembangan data mining tumbuh dengan sangat pesat. Hal ini seiring dengan tumbuhnya data yang semakin banyak dan digunakan dalam proses pengambilan kebijakan. Kebijakan yang diambil dengan menggunakan data dilakukan dengan pembuatan model data mining. Saat ini, data menjadi unsur penting dalam suatu perusahaan. Data menjadi aset yang dapat digunakan untuk mencari pola yang dapat digunakan dalam pengambilan kebijakan. Informasi dari model yang diolah dapat digunakan dalam memproyeksikan strategi atau kebijakan yang dilakukan untuk proses pengembangan bisnis. Proses penelusuran data yang besar harus dilakukan secara cermat. Semakin besar data semakin besar proses untuk melakukan pemilahan data yang sesuai dengan keperluan.

Data mining merupakan proses menemukan informasi dari suatu data yang tersimpan dalam suatu database atau dataset. Pembuatan model dilakukan dengan proses menggunakan algoritma atau rumus tertentu. Proses data mining menggunakan berbagai teknik seperti teknik dalam proses statistik, matematika, dan machine learning yang digunakan dalam melakukan identifikasi dan mengolah berbagai data menjadi informasi yang bermanfaat (Arhami & Nasir, 2020; Jollyta et al., 2020).

Salah satu model prediksi yang digunakan pada data mining adalah regresi linear. Analisis regresi dapat digunakan untuk melihat pengaruh antara variabel bebas (independen) dan variabel tidak bebas (dependen). Regresi linear dibedakan menjadi regresi sederhana dan regresi linear berganda. Regresi linear sederhana hanya terdapat satu variabel bebas dan satu variabel yang menjadi variabel tidak bebas dan regresi linear berganda apabila terdapat lebih dari satu variabel bebas. Kegunaan dari analisis regresi linear adalah untuk mengetahui arah dan seberapa besar pengaruh variabel independen terhadap variabel dependen. Variabel yang dapat mempengaruhi sering disebut variabel dependen atau tidak bebas dan variabel yang mempengaruhi variabel lain disebut variabel independen atau variabel bebas.. Model persamaannya matematika ditampilkan pada Pers. (1).

$$y = a_0 + A_1x_1 + A_2x_2 + \dots + A_nx_n \quad (1)$$

Di mana y adalah variabel dependen dan $x_1, x_2, \dots, x_n$ merupakan variabel independen, a merupakan nilai konstanta, dan b adalah nilai koefisien regresi (Kurniawan, 2016).

Model regresi linear dalam data mining menjadi salah satu model yang banyak digunakan. Penggunaan regresi linear dalam data mining menggunakan berbagai dataset baik dataset milik sendiri ataupun dataset publik. Salah satu dataset publik yang sering digunakan dalam pembuatan model data mining adalah dataset student_performance.csv yang diambil dari <https://archive.ics.uci.edu/ml/datasets.php>. Dataset ini berisi data yang diolah dari data siswa dan data keluarga pada sekolah menengah di Portugal. Dataset tersebut menjadi salah satu dataset yang digunakan dalam penelitian pembuatan model data mining. Setiyorini & Asmono (2020) menggunakan

Student Performance dataset untuk pembuatan model klasifikasi terutama dengan menggunakan K-Nearest Neighbour, Ünal (2021) membuat model klasifikasi dengan menggunakan Decision Tree, Random Forest dan Naive Bayes, Deepika & Sathyanarayana (2018) menggunakan Decision Tree, dan Oyedeji et al. (2020) yang melakukan analisis kinerja akademik siswa untuk mengetahui cara-cara meningkatkan kinerja individu siswa.

Model data mining untuk memprediksi keberhasilan siswa dengan dataset yang selain student performance dan menggunakan dataset yang bersifat privat dilakukan oleh Ofori et al. (2020) yang melakukan identifikasi model machine learning untuk melakukan prediksi kinerja siswa dan model machine learning yang tepat dalam meningkatkan pembelajaran bagi siswa. Bahri et al. (2022), membuat model yang diharapkan dapat membantu siswa dalam menentukan jurusan yang akan diambil dalam menempuh jenjang pendidikan tinggi. Hasil pengujian, faktor yang paling mempengaruhi kesalahan dalam mengambil jurusan di perguruan tinggi adalah variabel informasi jurusan dan pengujian yang dilakukan dengan menggunakan tiga algoritma, algoritma Decision Tree merupakan algoritma yang menghasilkan nilai akurasi tertinggi dengan tingkat akurasi tinggi 75,38%. Penelitian lain yang masih terkait data mining yang menggunakan data siswa dilakukan oleh Hendrian (2018), Putro et al. (2021), dan Ramadhani & Hendriyani (2021).

Penelitian data mining yang menggunakan berbagai dataset dan menggunakan model regresi linear sudah dilakukan dengan menggunakan berbagai aplikasi. Ariesanto & Ekka (2020) melakukan penelitian dengan menerapkan data mining dengan regresi linear. Regresi linear digunakan untuk melakukan prediksi harga suatu saham pada perusahaan pelayaran. Evaluasi dilakukan dengan nilai Root Mean Square Error. Nilai RMSE menunjukkan angka plus 7,522 dari data aktual harga penutupan saham. Gaol et al. (2019) menggunakan regresi linear berganda untuk melakukan prediksi data dalam ketersediaan buku. Penelitian serupa juga dilakukan oleh Rahayu et al. (2022), Sinaga et al. (2022), dan Siregar (2021).

Pembuatan model data mining dapat diimplementasikan dengan berbagai aplikasi baik yang berbasis dengan membuat program dan menggunakan aplikasi Visual Programming. Pengembangan model data mining yang menggunakan bahasa pemrograman sudah dilakukan oleh Sholeh et al. (2022). Penelitian dilakukan dengan menggunakan dataset asuransi kesehatan untuk memprediksi biaya asuransi. Pembuatan model menggunakan pemrograman Python dengan memanfaatkan berbagai library yang mendukung proses pembuatan model seperti pandas dan sklearn. Penelitian sejenis yang menggunakan pemrograman Python untuk data mining dilakukan oleh Kurniatullah & Pramudi (2017), N. et al. (2019), Nishadi (2019), dan Prabha et al. (2020).

Selain menggunakan bahasa pemrograman, pembuatan model data mining dapat menggunakan Visual Programming seperti RapidMiner. RapidMiner dapat digunakan untuk melakukan proses analisis pada data mining, text mining, dan analisis prediksi. RapidMiner menggunakan berbagai cara dan teknik

deskriptif serta prediksi dalam pembuatan model yang dapat digunakan dalam pengambilan keputusan (Chisholm, 2013). Penggunaan RapidMiner dalam pembuatan model tidak memerlukan program dan semua yang digunakan dalam pembuatan model sudah tersedia dalam bentuk operator. Pembuatan model menggunakan berbagai operator yang sesuai dan saling dikaitkan dalam membentuk suatu model. Proses pembuatan data mining dengan RapidMiner sudah dilakukan beberapa peneliti dengan berbagai dataset dan model serta algoritma yang digunakan. Penelitian tersebut di antaranya dilakukan oleh Chisholm (2013), Prasetyo et al. (2021), dan Sudarsono et al. (2021).

Berdasar latar belakang, tinjauan pustaka, dan studi literatur, proses data mining menjadi salah satu cara dalam memberikan informasi dalam bentuk model dalam pengambilan keputusan. Salah satu model yang dapat digunakan dalam pembuatan data mining adalah regresi linear. Batasan dalam penelitian ini adalah membuat model regresi linear dengan dataset student performance dan tidak semua atribut digunakan. Dataset student performance merupakan dataset publik, yang terdiri dari 395 data dan 33 atribut. Dataset tersebut dapat diunduh pada laman <https://archive.ics.uci.edu/dataset/320/student+performance>. Pertimbangan penggunaan dataset ini karena memiliki jumlah data dan atribut cukup banyak sehingga dapat dilakukan berbagai pengujian sehingga dapat ditentukan atribut apa saja yang mempengaruhi dalam pembuatan model. Dengan demikian, model yang dihasilkan diharapkan dapat digunakan dalam memprediksi nilai siswa.

DAFTAR ISI

PENDAHULUAN	2
DAFTAR ISI	5
BAB 1 METODE PENELITIAN	6
1.1 Dataset.....	6
1.2 Tahapan Penelitian.....	6
Bab 2 Hasil dan Pembahasan	7
2.1 Business Understanding.....	7
2.2 Data Understanding	7
2.3 Data Preparation	7
2.4 Pembuatan Model	9
Bab 3 Kesimpulan	15
Hasil perbandingan	15

BAB 1 METODE PENELITIAN


Metodologi penelitian dalam membuat model data mining regresi linear, menggunakan metodologi CRISP-DM. Pembuatan model dengan metodologi CRISP-DM terdapat enam tahapan, yaitu business understanding, data understanding, data preparation, modeling, evaluation, dan deployment (Hidayati et al., 2021).

1.1 Dataset

Dataset yang digunakan adalah StudentPerformance.csv. Sumber dataset ada pada laman <https://archive.ics.uci.edu/dataset/320/student+performance>. Dataset terdiri dari 395 baris dan 33 atribut.

1.2 Tahapan Penelitian

Tahapan penelitian dengan berdasar pada model CRISP-DM, langkah–langkah yang dilakukan di antaranya mempelajari dataset dan membersihkan dataset seperti memeriksa data kosong, memeriksa batasan nilai dan lainnya. Dalam pembuatan model, dataset dibagi menjadi dua terdiri dari 80% dataset digunakan untuk data training dan 20% digunakan untuk data testing. Gambar 1 merupakan tahapan dalam pembuatan model data mining.



Gambar 1

Bab 2 Hasil dan Pembahasan

2.1 Business Understanding

Langkah awal dalam penelitian adalah mengidentifikasi manfaat dan kegunaan dari model yang dikembangkan. Dataset dilakukan identifikasi keterkaitan antar atribut terutama dengan atribut yang menjadi label. Hasil dari model, model diharapkan dapat digunakan untuk melakukan identifikasi faktor-faktor yang berkontribusi terhadap kegagalan siswa dalam menempuh ujian dan dapat digunakan untuk melakukan prediksi nilai ujian akhir.


2.2 Data Understanding

Proses ini dilakukan dengan mengidentifikasi atribut yang ada dalam dataset. Atribut yang ada dilakukan proses pemilahan awal, di antaranya adalah menentukan atau memilih atribut yang tidak mempunyai keterkaitan dalam pembuatan model. Atribut yang tidak mempengaruhi dalam pembuatan model tidak akan digunakan.

2.3 Data Preparation

Data preparing sangat diperlukan dan bertujuan untuk mengolah data agar data tidak mengandung kesalahan. Pemeriksaan data yang dilakukan diantaranya memeriksa data kosong, data yang di luar ambang batas dan tipe data yang tidak sesuai. Proses data preparing yang dilakukan sebagai berikut.


1. Memilih atribut yang akan digunakan



Gambar 2

Tidak semua atribut digunakan, sehingga akan dipilih atribut yang mempengaruhi model. Dari 33 atribut yang ada, atribut sex, age, dan school tidak dipilih dalam proses pembuatan model. Atribut tersebut tidak saling mempengaruhi dalam pembuatan model. Gambar 2 menunjukkan penggunaan operator select atribut dalam proses pemilihan atribut.


2. Mengubah tipe data nominal menjadi numerik.



Gambar 3

Atribut yang berisi data selain numerik akan diubah menjadi atribut yang berisi data numerik. Atribut sex yang berisi nominal F dan M akan diubah menjadi 0 dan 1, atribut Mjob yang berisi other, services, at_home, teacher, dan health akan diubah menjadi numerik 0-4. Gambar 3 merupakan penggunaan operator nominal to numerical dalam proses mengubah tipe nominal menjadi numerik.


3. Mengganti data missing value dengan data tertentu.



Gambar 4

Semua isi dataset yang digunakan harus terisi data atau tidak boleh mengandung data kosong. Agar data tidak mengandung data kosong, data yang berisi nilai kosong akan diganti dengan data rata-rata pada masing-masing atribut. Proses untuk mengganti data kosong dengan data tertentu dapat menggunakan operator replace missing value. Gambar 4 memperlihatkan proses penggantian data kosong dengan nilai rata-rata.

4. Menentukan atribut yang menjadi label.



Gambar 5

Row No.	G3	address	famsize	Pstatus	Mjob	Fjob	reason	guardian
1	6	0	0	0	0	0	0	0
2	6	0	0	1	0	1	0	1
3	10	0	1	1	0	1	1	0
4	15	0	0	1	1	2	2	0
5	10	0	0	1	2	1	2	1


Gambar 6

Label yang digunakan dalam pembuatan model adalah G3. Gambar diatas menunjukkan penggunaan operator set role untuk menentukan atribut G3 menjadi label.

2.4 Pembuatan Model

Tahapan berikutnya adalah membuat model regresi linear dengan atribut yang sudah ditentukan dengan tahapan pemuatan model sebagai berikut.

1. Menampilkan bobot hasil matriks korelasi.




Gambar 7

attribute	weight
G2	0.905
G1	0.801
failures	0.360
Medu	0.217
higher	0.182
Fedu	0.152
goout	0.133
romantic	0.130
travelttime	0.117

Gambar 8

Matriks korelasi merupakan matriks yang memuat koefisien korelasi dari semua atribut yang digunakan. Hasil dari matriks dapat digunakan untuk memperoleh nilai kedekatan hubungan antar atribut. Gambar 7 menunjukkan penggunaan operator weight by Correlation untuk mengetahui keterkaitan antar atribut dan Gambar 8 memperlihatkan hasil pembobotan keterkaitan antar atribut terutama dengan atribut label yaitu G3.

2. Menentukan nilai bobot yang digunakan dalam proses pembuatan model.




Gambar 9

Row No.	G3	higher	Medu	Fedu	failures	G1	G2
1	6	0	4	4	0	5	6
2	6	0	1	1	0	5	5
3	10	0	1	1	3	7	8
4	15	0	4	2	0	15	14
5	10	0	3	3	0	6	10
6	15	0	4	3	0	15	15
7	11	0	2	2	0	12	12
8	6	0	4	4	0	6	5
9	19	0	3	2	0	16	18
10	15	0	3	4	0	14	15

Gambar 10

Hasil pembobotan pada Gambar sebelumnya, ditentukan batas nilai bobot yang digunakan. Dalam penelitian ini, batas pembobotan yang akan digunakan adalah pembobotan di atas 0,15. Batas ini dipilih dengan pertimbangan batas 0,15 masih mendekati batas korelasi cukup ($>0,25 - 0,5$) dan akan dilakukan pengujian, apakah atribut yang dibawah batas cukup mempengaruhi model. Atribut yang digunakan dalam membuat model adalah G2 (nilai ujian kedua), G1 (nilai ujian pertama), failures (berapa kali pernah tinggal kelas), Higher, Medu (tingkat pendidikan orang tua (ibu)), dan Fedu (tingkat pendidikan orang tua (ayah)). Proses untuk pemilihan bobot menggunakan operator select by weight dengan parameter pemilihan bobot di atas 0,15. Gambar berikut menunjukkan proses penggunaan operator select by weight.

3. Proses pembuatan model linear regresi



Gambar 11


LinearRegression

$$\begin{aligned} & 0.136 * \text{Medu} \\ & - 0.123 * \text{Fedu} \\ & - 0.235 * \text{failures} \\ & + 0.147 * \text{G1} \\ & + 0.972 * \text{G2} \\ & - 1.591 \end{aligned}$$

Gambar 12

Berdasar pada pembobotan, pembuatan model linear regresi dapat dilakukan. Gambar 11 merupakan penggunaan operator linear regresi dalam proses pembuatan model.

4. Pembuatan model dengan data training dan pengujian dengan data testing.



Gambar 13

Model yang dihasilkan pada Gambar 9, menggunakan semua data yang ada di dataset dan belum melakukan pengujian. Proses pembuatan model akan menggunakan data training dan proses evaluasi menggunakan data testing. Pembagian data dilakukan dengan membagi data


training sebanyak 80% dan data testing sebanyak 20%. Proses pembagian data menggunakan operator split data dan proses untuk melakukan pengujian menggunakan operator apply data. Gambar berikut merupakan proses pembuatan data dengan data training dan pengujian dengan data testing.

LinearRegression

```
0.136 * Medu
- 0.123 * Fedu
- 0.235 * failures
+ 0.147 * G1
+ 0.972 * G2
- 1.591
```


Gambar 14

5. Hasil model dalam bentuk grafik




Gambar 15

6. Evaluasi model



Gambar 16

Model yang sudah selesai dibangun, dilakukan proses evaluasi. Proses evaluasi dilakukan untuk melihat performance. Proses evaluasi dilakukan dengan menggunakan data testing yang sudah ditentukan sebanyak 20% dari dataset. Proses pengujian menggunakan operator performance. Gambar 16 merupakan proses pengujian dengan menggunakan operator performance dan Gambar 15 adalah hasil luaran dari performance.




Gambar 17

Bab 3 Kesimpulan

Hasil perbandingan

Berdasarkan hasil penelitian, terdapat beberapa perbandingan antara hasil penelitian dan hasil dalam artikel, beberapa diantaranya adalah :

1. Perbandingan hasil linear regresi



Gambar 18 : Artikel

LinearRegression

0.136 * Medu
- 0.123 * Fedu
- 0.235 * failures
+ 0.147 * G1
+ 0.972 * G2
- 1.591

Gambar 19 : Hasil penelitian

2. Perbandingan hasil prediksi

Row No.	G3	prediction(G3)	schoolsup	Medu	Fedu	failures	goout	Walc	absences	G1	G2
1	6	5.976	0	4	4	0	4	1	6	5	6
2	15	14.374	1	4	2	0	2	1	2	15	14
3	11	12.167	1	3	2	0	4	1	0	12	12
4	10	9.925	1	4	3	0	3	3	4	8	10
5	12	13.179	1	2	2	0	4	4	0	13	13
6	11	11.169	0	3	4	0	3	1	4	11	11
7	12	11.638	1	4	3	0	2	4	0	9	11
8	11	12.257	0	3	4	0	2	1	2	12	12
9	9	10.177	0	2	2	1	3	2	14	10	10
10	15	15.115	1	4	3	0	2	1	0	14	15
11	16	16.622	1	4	2	0	3	1	2	15	16
12	15	15.653	1	3	1	0	2	1	0	13	15
13	8	5.639	0	1	1	2	4	4	2	8	6
14	11	11.280	1	2	2	0	3	3	0	11	11

Gambar 20 : Artikel


Row No.	G3	prediction(G3)	higher	Medu	Fedu	failures	G1	G2
1	6	4.889	0	4	4	0	5	6
2	10	6.386	0	1	1	3	7	8
3	10	8.872	0	3	3	0	6	10
4	15	15.316	0	4	3	0	15	15
5	16	16.063	0	2	2	0	14	16
6	14	13.991	0	4	4	0	13	14
7	15	16.267	0	4	2	0	15	16
8	17	16.640	0	4	4	0	17	16
9	12	11.902	0	4	4	0	12	12
10	13	12.836	0	2	2	0	12	13
11	13	12.472	0	3	3	0	10	13
12	10	8.285	0	2	1	0	8	9
13	9	9.228	0	1	2	0	8	10
14	5	3.929	0	3	4	0	5	5
15	10	9.414	0	1	1	0	9	10

Gambar 21 : Hasil Penelitian

3. Perbandingan hasil RMSE (Root Mean Squared Error) / Luaran performance



Gambar 22 : Artikel



Gambar 23 : Hasil penelitian

4. Lampiran Dataset

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U
1	school	sex	age	address	famsize	Pstatus	Medu	Fedu	Mjob	Fjob	reason	guardian	traveltime	studytime	failures	schoolsup	famsup	paid	activities	nursery	high
2	GP	F	18	U	GT3	A		4	4 at_home	teacher	course	mother	2	2	0	yes	no	no	no	yes	yes
3	GP	F	17	U	GT3	T		1	1 at_home	other	course	father	1	2	0	no	yes	no	no	yes	yes
4	GP	F	15	U	LE3	T		1	1 at_home	other	other	mother	1	2	3	yes	no	yes	no	yes	yes
5	GP	F	15	U	GT3	T		4	2 health	services	home	mother	1	3	0	no	yes	yes	no	yes	yes
6	GP	F	16	U	GT3	T		3	3 other	other	home	father	1	2	0	no	yes	yes	no	yes	yes
7	GP	M	16	U	LE3	T		4	3 services	other	reputation	mother	1	2	0	no	yes	yes	yes	yes	yes
8	GP	M	16	U	LE3	T		2	2 other	other	home	mother	1	2	0	no	yes	yes	no	yes	yes
9	GP	F	17	U	GT3	A		4	4 other	teacher	home	mother	2	2	0	yes	yes	no	no	yes	yes
10	GP	M	15	U	LE3	A		3	2 services	other	home	mother	1	2	0	no	yes	yes	no	yes	yes
11	GP	M	15	U	GT3	T		3	4 other	other	home	mother	1	2	0	no	yes	yes	yes	yes	yes
12	GP	F	15	U	GT3	T		4	4 teacher	health	reputation	mother	1	2	0	no	yes	yes	no	yes	yes
13	GP	F	15	U	GT3	T		2	1 services	other	reputation	father	3	3	0	no	yes	no	yes	yes	yes
14	GP	M	15	U	LE3	T		4	4 health	services	course	father	1	1	0	no	yes	yes	yes	yes	yes
15	GP	M	15	U	GT3	T		4	3 teacher	other	course	mother	2	2	0	no	yes	yes	no	yes	yes
16	GP	M	15	U	GT3	A		2	2 other	other	home	other	1	3	0	no	yes	no	no	yes	yes
17	GP	F	16	U	GT3	T		4	4 health	other	home	mother	1	1	0	no	yes	no	no	yes	yes
18	GP	F	16	U	GT3	T		4	4 services	services	reputation	mother	1	3	0	no	yes	yes	yes	yes	yes
19	GP	F	16	U	GT3	T		3	3 other	other	reputation	mother	3	2	0	yes	yes	no	yes	yes	yes
20	GP	M	17	U	GT3	T		3	2 services	services	course	mother	1	1	3	no	yes	no	yes	yes	yes
21	GP	M	16	U	LE3	T		4	3 health	other	home	father	1	1	0	no	no	yes	yes	yes	yes
22	GP	M	15	U	GT3	T		4	3 teacher	other	reputation	mother	1	2	0	no	no	no	no	yes	yes
23	GP	M	15	U	GT3	T		4	4 health	health	other	father	1	1	0	no	yes	yes	no	yes	yes

Dataset terdiri dari 33 atribut dengan 395 data, yang dapat diunduh pada tautan

<https://archive.ics.uci.edu/dataset/320/student+performance>